

**BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
PHÂN HIỆU TRƯỜNG ĐẠI HỌC THỦY LỢI
BỘ MÔN CÔNG NGHỆ THÔNG TIN**



BÁO CÁO ĐỒ ÁN

**TÊN ĐỀ TÀI: NGHIÊN CỨU VÀ PHÁT TRIỂN HỆ THỐNG RAG
HỖN HỢP ĐA PHƯƠNG THỨC VỚI KIẾN TRÚC
BẢO TOÀN VÀ KIỂM CHỨNG DẪN CHỨNG**

Giảng viên:	TS. Hoàng Văn Quý
Sinh viên thực hiện:	2351267275 - Nguyễn Văn Tấn Phát
Lớp:	S26-65TTNT

TP. Hồ Chí Minh, ngày ... tháng ... năm 2026

This image shows a full page of white paper with horizontal dotted lines. The lines are evenly spaced and run across the width of the page, providing a guide for handwriting practice. There are no margins, text, or other markings on the page.

Chữ ký của giảng viên

LỜI CAM ĐOAN

Em xin cam đoan báo cáo đồ án này được thực hiện dựa trên quá trình khảo sát tài liệu, phân tích bài toán, thiết kế hệ thống và thực nghiệm dưới sự hướng dẫn của giảng viên. Các số liệu, bảng biểu và nhận định trong báo cáo được trình bày theo đúng phạm vi triển khai của đồ án.

Tính trung thực của nội dung, kết quả thực nghiệm và các nhận định trong báo cáo thuộc trách nhiệm của sinh viên thực hiện.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến TS. Hoàng Văn Quý vì những góp ý và định hướng trong quá trình thực hiện đồ án. Từ các góp ý này, phạm vi bài toán hỏi đáp tài liệu được xác định rõ hơn, đặc biệt ở các yêu cầu về truy vết nguồn, kiểm chứng dẫn chứng và hạn chế thông tin thiếu căn cứ.

Em xin cảm ơn Bộ môn Công nghệ thông tin, Phân hiệu Trường Đại học Thủy Lợi tại Thành phố Hồ Chí Minh đã tạo điều kiện học tập và nghiên cứu. Sự hỗ trợ của gia đình, bạn bè và các anh chị cũng là nguồn động viên quan trọng trong quá trình hoàn thiện báo cáo.

TÓM TẮT

Trong hệ thống hỏi đáp truy xuất tăng cường (Retrieval-Augmented Generation - RAG), tri thức từ kho tài liệu bên ngoài được đưa vào ngữ cảnh của mô hình ngôn ngữ lớn [1], [2]. Cách tiếp cận này phù hợp với bài toán hỏi đáp tài liệu, nhưng độ tin cậy phụ thuộc vào việc bằng chứng nguồn có được giữ lại trong toàn bộ pipeline hay không. Với PDF nhiều cột, bảng tính, ảnh quét, chữ viết tay, hình ảnh và audio, việc quy đổi nội dung thành các đoạn văn bản phẳng có thể làm mất thông tin về trang, bbox, block, dòng bảng hoặc mốc thời gian. Khi các dấu vết này không được lưu cùng nội dung, trích dẫn trở nên khó kiểm tra và câu trả lời có thể thiếu căn cứ trực tiếp [3], [4].

Trong đồ án này, AgentBook được trình bày như một hệ thống GraphRAG đa phương thức theo hướng bảo toàn dẫn chứng. Điểm mới của hệ thống không nằm ở việc đề xuất một thuật toán RAG hoàn toàn mới, mà nằm ở cách tổ chức pipeline: Evidence Unit được xem là đơn vị trung tâm cho nạp liệu, truy xuất, sinh câu trả lời và kiểm chứng. Mỗi Evidence Unit lưu nội dung trích xuất cùng `owner_id`, `collection_id`, `material_id`, `page`, `block_id`, `bbox`, `source_language`, độ tin cậy OCR, audio timestamp hoặc table metadata khi có.

Trên lớp biểu diễn này, AgentBook sử dụng MongoDB làm source of truth cho metadata, chunks, entities, relations, events và logs; Qdrant được dùng cho dense, sparse và visual vectors. Ở bước truy vấn, QueryService, InferenceEngine, QueryRouter, HybridRetriever, GraphRetriever, VisualRetriever, reranker và guardrails được phối hợp theo một pipeline có phạm vi truy cập rõ ràng. Thử nghiệm cục bộ với Qwen2.5-7B-Instruct, Qwen2.5-VL-3B-Instruct và BGE-M3 [5], [6], [7] trên 294 câu hỏi ghi nhận Recall@5 là 0,79, Answer F1 là 0,67, Supported-claim rate là 0,76 và Refusal F1 là 0,36. Các giá trị này gợi ý rằng thiết kế bảo toàn dẫn chứng có ý nghĩa trong các tình huống câu trả lời cần được đối chiếu với tài liệu nguồn.

MỤC LỤC

LỜI CAM ĐOAN	1
LỜI CẢM ƠN	2
TÓM TẮT	3
DANH MỤC CÁC TỪ VIẾT TẮT	6
MỞ ĐẦU	9
1. Tính cấp thiết của đề tài	9
2. Mục tiêu nghiên cứu.....	9
3. Đối tượng và phạm vi nghiên cứu.....	10
4. Phương pháp nghiên cứu	10
5. Bố cục báo cáo	10
CHƯƠNG 1: GIỚI THIỆU VÀ PHÁT BIỂU BÀI TOÁN	11
1.1. Bối cảnh và động lực nghiên cứu.....	11
1.2. Khoảng trống nghiên cứu và ý tưởng cốt lõi	11
1.3. Mục tiêu và đóng góp chính	12
CHƯƠNG 2: KIẾN TRÚC HỆ THỐNG VÀ QUY TRÌNH KỸ THUẬT.....	14
2.1. Thiết kế dữ liệu Evidence Unit và mô hình lưu trữ	15
2.2. Quy trình nạp liệu đa phương thức và tiền xử lý	16
2.3. Chiến lược phân mảnh dữ liệu	17
2.4. Trích xuất đồ thị tri thức nhẹ	18
2.5. Định tuyến truy vấn và xử lý đa ngữ.....	20
2.6. Truy xuất lai và tái xếp hạng	20
2.7. Lập kế hoạch truy xuất Agentic	21
2.8. Bộ xử lý bảng biểu tắt định.....	23
2.9. Kiểm chứng sau sinh	23
CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	25
3.1. Thiết lập thực nghiệm.....	25
3.2. Bộ dữ liệu đánh giá	25
3.3. Chỉ số đo lường.....	27
3.4. Kết quả thực nghiệm	28
KẾT LUẬN	31

TÀI LIỆU THAM KHẢO	32
--------------------------	----

DANH MỤC CÁC TỪ VIẾT TẮT

Bảng A.1. Danh mục thuật ngữ và từ viết tắt

Từ viết tắt	Tiếng Anh/Thuật ngữ	Ý nghĩa trong đồ án
RAG	Retrieval-Augmented Generation	Kiến trúc sinh câu trả lời dựa trên tri thức truy xuất từ tài liệu.
LLM	Large Language Model	Mô hình dùng để hiểu truy vấn và tạo câu trả lời.
VLM	Vision-Language Model	Mô hình xử lý đồng thời hình ảnh và ngôn ngữ.
OCR	Optical Character Recognition	Nhận dạng ký tự quang học từ ảnh hoặc tài liệu quét.
SLEC	Sentence-Level Evidence Coverage	Cơ chế kiểm tra mức độ được hỗ trợ của từng câu trả lời.
RRF	Reciprocal Rank Fusion	Thuật toán hợp nhất kết quả từ nhiều bộ truy xuất.
BBox	Bounding Box	Vùng tọa độ xác định vị trí thông tin trên trang.
KG	Knowledge Graph	Đồ thị tri thức dùng để biểu diễn thực thể, quan hệ và sự kiện có liên kết với bằng chứng nguồn.
VDB	Vector Database	Cơ sở dữ liệu vector phục vụ truy xuất dense, sparse và visual vectors.
MMR	Maximal Marginal Relevance	Cơ chế đa dạng hóa kết quả truy xuất nhằm giảm trùng lặp bằng chứng.

DANH MỤC BẢNG BIỂU

Bảng A.1. Danh mục thuật ngữ và từ viết tắt	6
Bảng 2.1. Cấu trúc dữ liệu Evidence Unit.....	16
Bảng 2.2. Vai trò của các thành phần trong kiến trúc AgentBook	22
Bảng 3.1. Cơ cấu bộ dữ liệu đánh giá	26
Bảng 3.2. So sánh hiệu năng tổng thể giữa các cấu hình	28
Bảng 3.3. Đóng góp của từng thành phần kỹ thuật trong Ladder Ablation	30

DANH MỤC CÁC HÌNH

Hình 2.1. Tổng quan kiến trúc RAG đa phương thức bảo toàn dẫn chứng	13
Hình 2.2. Kiến trúc triển khai AgentBook theo các lớp chức năng.....	13
Hình 2.3. Quy trình nạp liệu đa phương thức và chuẩn hóa Evidence Unit.....	15
Hình 2.4. Mô hình đồ thị tri thức nhẹ lưu trên MongoDB	17
Hình 2.5. Truy xuất tăng cường đồ thị và cơ chế Graph Probe	17
Hình 2.6. Pipeline truy xuất lai văn bản và thị giác.....	19
Hình 2.7. Hợp nhất bằng chứng và đóng gói ngữ cảnh	20
Hình 2.8. Kiểm chứng trích dẫn sau sinh và công kiểm soát chất lượng	22
Hình 3.1. Quy trình đánh giá thực nghiệm và ablation	23
Hình 3.2. Quy trình tạo bộ dữ liệu đánh giá cho RAG	26

MỞ ĐẦU

1. Tính cấp thiết của đề tài

Tài liệu số trong thực tế thường gồm nhiều dạng nội dung, chẳng hạn văn bản, bảng biểu, ảnh quét, biểu đồ, chữ viết tay, audio và dữ liệu đa ngôn ngữ. Trong RAG, tri thức từ kho tài liệu bên ngoài được đưa vào ngữ cảnh của mô hình để phục vụ sinh câu trả lời [1], [2]. Tuy nhiên, khi tài liệu được chuyển thành các đoạn văn bản phẳng, thông tin về trang, bbox, block, dòng bảng hoặc mốc thời gian có thể không còn được bảo toàn đầy đủ.

Từ yêu cầu đó, trọng tâm của đề tài được đặt vào bài toán hỏi đáp tài liệu đa phương thức có truy vết nguồn. Câu trả lời cần liên kết được với vùng thông tin cụ thể trong tài liệu, đồng thời các bước truy xuất và kiểm chứng cần được giới hạn theo phạm vi owner_id, collection_id hoặc material_id. Điều kiện này là cơ sở để kết quả có thể được kiểm tra lại và đề hạn chế các khẳng định thiếu căn cứ.

2. Mục tiêu nghiên cứu

Mục tiêu nghiên cứu là thiết kế và triển khai thử nghiệm AgentBook cho bài toán hỏi đáp trên tài liệu đa phương thức có yêu cầu bảo toàn và kiểm chứng dẫn chứng. Phạm vi được xác định theo pipeline hiện tại của dự án, từ upload tài liệu, parsing, cleaning, chunking, embedding, index, retrieval, reranking, context construction, LLM/VLM generation đến guardrails và observability.

- Một mô hình Evidence Unit dùng để lưu nội dung trích xuất kèm provenance gồm owner_id, collection_id, material_id, page, block_id, bbox, source_language, OCR confidence, table metadata hoặc audio timestamp khi có.
- Một pipeline nạp liệu và truy xuất gồm Docling/OCR/Whisper/Spreadsheet parser, BGE-M3 dense-sparse retrieval, SigLIP visual retrieval, Qdrant RRF, cross-encoder reranking và đồ thị tri thức nhẹ lưu trên MongoDB [6], [7], [8].
- Một chuỗi kiểm chứng sau sinh gồm EvidenceValidator, citation injection, Sentence-Level Evidence Coverage, Citation Alignment, Quality Gate và refusal policy, kèm ghi log bằng RequestTrace và QueryLog.

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu gồm RAG, GraphRAG, truy xuất lai, xử lý tài liệu đa phương thức, mô hình ngôn ngữ lớn, mô hình ngôn ngữ - thị giác, OCR, embedding đa chức năng và các kỹ thuật kiểm chứng dẫn chứng [2], [6], [8]. Các kỹ thuật này được xem xét trong phạm vi một hệ thống document QA có provenance và scope truy cập rõ ràng.

Phạm vi thực nghiệm được giới hạn trong bộ dữ liệu cục bộ gồm PDF, bảng tính, ảnh quét và các dạng tài liệu mô phỏng pipeline hiện tại. Trọng tâm của đề án là thiết kế kiến trúc, triển khai thử nghiệm và đánh giá tính khả thi của hệ thống; hệ thống chưa được xem như một nền tảng thương mại hoàn chỉnh.

4. Phương pháp nghiên cứu

Phương pháp nghiên cứu gồm hai phần: khảo sát tài liệu và thực nghiệm hệ thống. Ở phần lý thuyết, các công trình liên quan đến RAG, benchmark RAG, xử lý ngữ cảnh dài, VLM, embedding đa chức năng và kiểm chứng trích dẫn được xem xét [2], [3], [4], [6], [7].

Ở phần thực nghiệm, AgentBook được triển khai theo pipeline gồm upload, parse-index, EvidenceMap, chunking, KG extraction, embedding, hybrid retrieval, graph/visual retrieval, reranking, context packing, generation và quality finalization. Kết quả của các cấu hình baseline được dùng làm cơ sở phân tích vai trò của từng thành phần kỹ thuật.

5. Bố cục báo cáo

Báo cáo gồm ba chương chính. Chương 1 nêu bối cảnh, bài toán và các đóng góp của đề án. Chương 2 trình bày kiến trúc AgentBook và quy trình kỹ thuật. Chương 3 trình bày thiết lập thực nghiệm, kết quả đánh giá và phân tích thử nghiệm thành phần.

CHƯƠNG 1: GIỚI THIỆU VÀ PHÁT BIỂU BÀI TOÁN

1.1. Bối cảnh và động lực nghiên cứu

Các mô hình ngôn ngữ lớn được sử dụng ngày càng nhiều trong tác vụ hỏi đáp và tổng hợp tài liệu. Tuy nhiên, trong môi trường học thuật hoặc doanh nghiệp, mức độ trôi chảy của câu trả lời chưa đủ để đánh giá độ tin cậy. Nguồn thông tin, vị trí trong tài liệu, quyền truy cập dữ liệu và mức độ hỗ trợ của nguồn đối với từng khẳng định vẫn cần được xác định rõ.

Trong RAG, các đoạn tài liệu liên quan được truy xuất và đưa vào ngữ cảnh của mô hình ngôn ngữ [1], [2]. Cơ chế này bổ sung tri thức ngoài mô hình, nhưng vẫn phụ thuộc vào chất lượng parsing, chunking, embedding, hydration từ source of truth và kiểm chứng trích dẫn. Nếu thông tin trang, bố cục, bbox hoặc block_id không được giữ lại, việc kiểm chứng câu trả lời sau cùng sẽ gặp khó khăn. Vấn đề này thường xuất hiện trong tài liệu dài hoặc đa phương thức, nơi thông tin liên quan có thể nằm rải rác hoặc bị suy giảm trong ngữ cảnh dài [3].

Từ bối cảnh trên, ba nhóm vấn đề sau được xem xét trong đồ án:

- Mất cấu trúc tài liệu gốc: khi tài liệu được chuyển thành văn bản phẳng, quan hệ giữa tiêu đề, đoạn văn, bảng biểu, hình ảnh và vị trí trên trang bị suy giảm.
- Trích dẫn chưa đủ khả năng kiểm chứng: nhiều hệ thống chỉ dẫn đến tài liệu hoặc đoạn văn rộng, chưa chỉ ra được vị trí chính xác của thông tin hỗ trợ cho từng câu trả lời.
- Dữ liệu đa phương thức khó xử lý thống nhất: bảng số liệu, ảnh quét, biểu đồ và tài liệu đa ngữ cần các phương pháp xử lý riêng thay vì chỉ xem như văn bản thuần.

1.2. Khoảng trống nghiên cứu và ý tưởng cốt lõi

Khoảng trống chính nằm ở khả năng bảo toàn vết dẫn chứng xuyên suốt pipeline. Một đoạn tài liệu có thể được truy xuất đúng, nhưng nếu từng khẳng định trong câu trả lời không được liên kết với bằng chứng cụ thể thì độ tin cậy vẫn khó được đánh giá. Đây là nội dung cần được chú ý trong các tiêu chí negative rejection và citation grounding của RAG [4].

Evidence Unit được lựa chọn làm đơn vị biểu diễn tri thức trung tâm. Mỗi Evidence Unit gồm nội dung trích xuất, trang nguồn, vùng tọa độ, loại khối, loại dữ liệu, source_language, độ tin cậy và metadata đặc thù như table cell hoặc audio timestamp. Cấu trúc này cho phép nội dung và bối cảnh xuất hiện của nội dung trong tài liệu gốc được lưu cùng nhau.

Trọng tâm kỹ thuật vì vậy được dịch chuyển từ truy xuất đoạn văn sang truy xuất bằng chứng. Ở bước sinh câu trả lời, từng câu khẳng định được đối chiếu với các Evidence Unit đã truy xuất. Khi bằng chứng không đạt mức hỗ trợ cần thiết, việc giảm mức khẳng định hoặc từ chối trả lời có cơ sở kỹ thuật rõ hơn.

1.3. Mục tiêu và đóng góp chính

Mục tiêu nghiên cứu

- Thiết kế và triển khai thử nghiệm AgentBook cho việc nạp, biểu diễn và truy xuất tài liệu đa phương thức theo hướng bảo toàn dẫn chứng, với phạm vi xử lý theo owner, collection và material.
- Thiết kế cơ chế kiểm chứng sau sinh ở mức câu để đánh giá mức độ được hỗ trợ của từng khẳng định và sự phù hợp giữa citation marker với bằng chứng nguồn.
- Đánh giá hệ thống trên bộ dữ liệu câu hỏi thực tế, đồng thời so sánh với các cấu hình baseline để quan sát tác động của truy xuất lai, graph augmentation, reranking và guardrails.


Đóng góp chính

1. Pipeline nạp liệu bảo toàn dẫn chứng: PDF, DOCX, PPTX, bảng tính, ảnh quét, chữ viết tay, audio và figure/chart được chuẩn hóa về Evidence Unit có provenance giàu siêu dữ liệu.
2. Truy xuất lai có hỗ trợ đồ thị tri thức: BGE-M3 dense-sparse retrieval, Qdrant RRF, visual retrieval, graph path retrieval, graph boost và graph probe được kết hợp trong một lớp truy xuất có scope bảo mật.

3. Kiểm chứng sau sinh: EvidenceValidator, SLEC, Citation Alignment, Quality Gate và refusal policy được sử dụng để nhận diện các khẳng định chưa được bằng chứng hỗ trợ đầy đủ.


4. Bộ xử lý bảng tắt định và observability: các phép toán số học trên bảng được xử lý bằng mã nguồn, trong khi RequestTrace, QueryLog và PipelineJob được dùng để ghi lại trạng thái pipeline và các quyết định kiểm chứng.

CHƯƠNG 2: KIẾN TRÚC HỆ THỐNG VÀ QUY TRÌNH KỸ THUẬT



Hình 2.1. Tổng quan kiến trúc RAG đa phương thức bảo toàn dẫn chứng

Ở Hình 2.1, pipeline tổng quát được tổ chức quanh Evidence Unit, đặt giữa tài liệu gốc, lớp truy xuất và bước kiểm chứng. Hai luồng xử lý chính được thể hiện: luồng hình thành câu trả lời từ tài liệu đa phương thức và luồng đối chiếu trích dẫn quay lại lớp lưu trữ vector. Với cách tổ chức này, kiểm chứng dẫn chứng được xem như một điều kiện trong quy trình xử lý thay vì chỉ là phần bổ sung sau khi sinh câu trả lời.



Hình 2.2. Kiến trúc triển khai AgentBook theo các lớp chức năng

Ở Hình 2.2, kiến trúc AgentBook được tách thành các lớp chức năng tương ứng với pipeline hiện tại: API/Service, Ingestion Pipeline, Storage Layer và Query/Retrieval/Generation. Lớp nạp liệu phụ trách thông tin gốc của tài liệu; lớp lưu trữ quản lý Evidence Unit, chỉ mục, KG và logs; luồng truy vấn gồm router, processor, retriever, reranker, context packing, LLM/VLM generation và guardrails. Cách phân tách này giúp trách nhiệm của từng thành phần được giới hạn rõ hơn.

2.1. Thiết kế dữ liệu Evidence Unit và mô hình lưu trữ

Ba lớp dữ liệu được sử dụng trong AgentBook gồm nội dung tài liệu, chỉ mục truy xuất và quan hệ tri thức. Cấu trúc này lưu các thông tin cần thiết cho kiểm chứng, đồng thời phục vụ tìm kiếm theo ngữ nghĩa trên nhiều loại tài liệu.

- Metadata tài liệu, `material_pages`, `chunks`, `entities`, `relations`, `events`, `pipeline_jobs`, `query_logs` và `translation_cache` được lưu trong MongoDB. Lớp này đóng vai trò source of truth cho citation, provenance, trạng thái pipeline và observability.
- Vector dense, sparse và visual vectors được lưu trong Qdrant. Text collection lưu BGE-M3 dense vector và sparse lexical weights; visual collection lưu SigLIP vectors cho figure, crop hoặc image block.

- Mọi truy vấn được lọc theo owner_id, collection_id và material_id khi có. Ràng buộc này được xem là invariant của pipeline, nhằm tránh retrieval ngoài phạm vi dữ liệu được cấp quyền.

Bảng 2.1. Cấu trúc dữ liệu Evidence Unit


Trường dữ liệu	Vai trò	Ý nghĩa kiểm chứng
content	Lưu nội dung đã trích xuất	Nội dung dùng cho truy xuất và tạo câu trả lời.
material_id	Định danh tài liệu nguồn	Cho biết bằng chứng thuộc tài liệu nào.
page	Trang nguồn	Hỗ trợ người dùng đối chiếu trực tiếp trên tài liệu gốc.
bbox	Vùng tọa độ trên trang	Giúp xác định chính xác vùng chứa thông tin.
block_id	Thứ tự khối đọc	Giữ thứ tự đọc và ngữ cảnh bố cục.
modality	Loại dữ liệu	Xác định loại dữ liệu của bằng chứng.
confidence	Độ tin cậy trích xuất	Hỗ trợ đánh giá độ tin cậy của dữ liệu trích xuất.

2.2. Quy trình nạp liệu đa phương thức và tiền xử lý

Tài liệu được xử lý bất đồng bộ nhằm giảm thời gian chờ khi tệp tải lên có dung lượng lớn hoặc nhiều trang. Quy trình từ upload đến indexed material gồm validation, lưu raw file, tạo Material/PipelineJob, parsing, normalization, EvidenceMap, chunking, KG extraction, embedding và index vào MongoDB/Qdrant.

1. Phân tích cấu trúc. Với PDF, DOCX và PPTX, Docling được sử dụng để nhận diện tiêu đề, đoạn văn, bảng biểu và hình ảnh. Với Excel hoặc CSV, dữ liệu dạng lưới được chuyển thành bảng có cấu trúc. Với ảnh quét, chữ viết tay hoặc audio, OCR/VLM hoặc Faster-Whisper được sử dụng tùy loại dữ liệu và chất lượng đầu vào [8].

2. Chuẩn hóa Evidence Unit. Mỗi khối nội dung sau khi trích xuất được đưa về cùng một định dạng dẫn chứng, gồm nội dung, trang, bbox, block_id, source_language, modality, confidence và metadata đặc thù cho bảng, hình hoặc audio.
3. Tạo chỉ mục truy xuất. Nội dung được làm sạch, loại trùng, phân mảnh, làm giàu ngữ cảnh khi cấu hình cho phép, sau đó được mã hóa thành dense, sparse hoặc visual vectors. Metadata được lưu lại để phục vụ lọc, kiểm chứng và hiển thị dẫn chứng.



Hình 2.3. Quy trình nạp liệu đa phương thức và chuẩn hóa Evidence Unit

Ở Hình 2.3, vai trò của bước chuẩn hóa trung gian được đặt trước quá trình tạo chỉ mục. Do PDF, PowerPoint, bảng tính, ảnh quét và audio có cấu trúc khác nhau, một dạng biểu diễn chung là cần thiết. Khi mọi nội dung được quy đổi thành Evidence Unit, page, bbox, block_id, timestamp và source_language được giữ lại cho các bước truy vết và kiểm chứng.

2.3. Chiến lược phân mảnh dữ liệu

Phân mảnh dữ liệu có ảnh hưởng trực tiếp đến chất lượng truy xuất. Chunk quá ngắn có thể thiếu ngữ cảnh, trong khi chunk quá dài có thể làm giảm độ chính xác khi tìm kiếm. Vì vậy, chiến lược phân mảnh được lựa chọn theo loại tài liệu, đồng thời vẫn giữ quan hệ giữa chunk và EvidenceBlock nguồn.


- Layout-Aware Chunking: ranh giới tiêu đề, đoạn văn, bảng và vùng trang được ưu tiên để giữ cấu trúc tài liệu gốc.

- Semantic Chunking: embedding của các block liên kế được dùng để xác định điểm ngắt tự nhiên, với fallback về layout chunker khi embedding không khả dụng.
- Slide-Aware Chunking: ranh giới slide được giữ để tránh trộn nội dung giữa các trang trình chiếu.
- Audio Chunking: transcript được gom theo cửa sổ thời gian, trong đó start_seconds và end_seconds được giữ lại để truy vết về đoạn âm thanh.

2.4. Trích xuất đồ thị tri thức nhẹ


Đối với câu hỏi bắc cầu, thông tin cần thiết thường nằm ở nhiều đoạn khác nhau. Vì vậy, ngoài truy xuất theo embedding và từ khóa, đồ thị tri thức nhẹ được sử dụng để biểu diễn thực thể, quan hệ và sự kiện ngay trong MongoDB, không phụ thuộc vào một graph database riêng.

- Trích xuất thực thể: người, tổ chức, địa điểm, khái niệm và thực thể miền chuyên biệt được nhận diện từ các EvidenceBlock đã qua lọc section.
- Trích xuất quan hệ và sự kiện: các cạnh quan hệ và event nodes được gắn với evidence refs hoặc evidence_chunk_ids để quan hệ vẫn có căn cứ kiểm tra lại.
- Đồng nhất và kiểm soát chất lượng: các biến thể tên gọi, viết tắt hoặc đa ngôn ngữ được hợp nhất; các entity/relation dưới ngưỡng tin cậy được loại bỏ bằng quality gate.



Hình 2.4. Mô hình đồ thị tri thức nhẹ lưu trên MongoDB

Ở Hình 2.4, đồ thị tri thức nhẹ được tổ chức sao cho thực thể, quan hệ và sự kiện đều gắn ngược về Evidence Unit nguồn. Mô hình này không thay thế vector retrieval mà bổ sung tín hiệu quan hệ cho các câu hỏi bắc cầu. Mỗi cạnh quan hệ đều có evidence refs, nhờ vậy quan hệ được dùng trong truy xuất vẫn có căn cứ để kiểm tra lại.



Hình 2.5. Truy xuất tăng cường đồ thị và cơ chế Graph Probe

Ở Hình 2.5, vai trò của đồ thị trong giai đoạn truy xuất được thể hiện qua ba cơ chế. Graph-Primary dùng quan hệ trong đồ thị như một nguồn bằng chứng; Graph Boost điều chỉnh thứ hạng của các chunk chứa thực thể hoặc quan hệ đã khớp; Graph Probe mở

rộng sang các nút lân cận để bù phần ngữ cảnh còn thiếu. Các cơ chế này phù hợp với câu hỏi cần kết nối thông tin từ nhiều vị trí trong tài liệu.

2.5. Định tuyến truy vấn và xử lý đa ngữ


Khi nhận câu hỏi, truy vấn được định tuyến theo ý định thay vì được xử lý bằng một luồng duy nhất. QueryRouter xác định route, modality ưu tiên, nhu cầu dùng graph, multi-query, MMR hoặc agentic path. Câu hỏi tính toán được chuyển đến table executor; câu hỏi liên quan hình ảnh kích hoạt visual retrieval; câu hỏi so sánh hoặc bắc cầu có thể sử dụng thêm graph retrieval.

Với truy vấn tiếng Việt trên tài liệu tiếng Anh, việc tìm kiếm được thực hiện song song trên biểu diễn tiếng Việt và tiếng Anh. QueryProcessor có thể bổ sung bản dịch, multi-query hoặc HyDE passage như tín hiệu truy xuất; ngôn ngữ câu trả lời vẫn được giữ theo ngôn ngữ truy vấn ban đầu.

2.6. Truy xuất lại và tái xếp hạng

Trong truy xuất lại, hai nhóm tín hiệu được kết hợp: dense retrieval phù hợp với khớp ngữ nghĩa, còn sparse retrieval phù hợp với mã số, tên riêng và thuật ngữ chính xác. BGE-M3 hỗ trợ đồng thời dense vector và sparse lexical weights, trong khi Qdrant RRF được dùng để hợp nhất kết quả khi điều kiện hệ thống cho phép [7].

Sau truy xuất ban đầu, kết quả từ Qdrant được hydrate lại từ MongoDB để phục hồi citation-grade evidence. Từng Evidence Unit sau đó được cross-encoder reranker chấm điểm theo mức độ liên quan với câu hỏi; khi cần, MMR được dùng để giảm trùng lặp giữa các bằng chứng.




Hình 2.6. Pipeline truy xuất lai văn bản và thị giác

Ở Hình 2.6, quy trình truy xuất được chia thành nhiều kênh. Dense retrieval xử lý các câu hỏi diễn đạt khác văn bản gốc; sparse retrieval giữ tốt tên riêng, mã số và thuật ngữ; visual retrieval hỗ trợ nội dung hình ảnh hoặc vùng cắt trên trang. Các kết quả được hợp nhất bằng Reciprocal Rank Fusion, được hydrate từ MongoDB, rồi được tái xếp hạng bằng cross-encoder trước khi đưa vào mô hình sinh.

2.7. Lập kế hoạch truy xuất Agentic

Với câu hỏi phức tạp, cơ chế lập kế hoạch truy xuất có kiểm soát được sử dụng. Đây không phải một ReAct agent tự do, mà là một lớp điều phối có giới hạn. Câu hỏi được tách thành các câu hỏi phụ; công cụ phù hợp như hybrid text search, graph relation search hoặc visual search được chọn cho từng nhánh; bằng chứng sau đó được gom lại và đưa về cùng pipeline kiểm chứng.



Hình 2.7. Hợp nhất bằng chứng và đóng gói ngữ cảnh

Ở Hình 2.7, tập bằng chứng truy xuất được chuyển thành ngữ cảnh đầu vào cho LLM/VLM. Thay vì nối các đoạn văn bản một cách tuần tự, bằng chứng được hợp nhất theo độ liên quan, loại bỏ trùng lặp và đóng gói thành các khối có mã trích dẫn. Bố trí bằng chứng quan trọng ở đầu và cuối ngữ cảnh được sử dụng để giảm rủi ro mất thông tin ở giữa ngữ cảnh dài, đồng thời giữ ánh xạ giữa câu trả lời và nguồn trích dẫn.

Bảng 2.2. Vai trò của các thành phần trong kiến trúc AgentBook

Thành phần	Đầu vào	Đầu ra	Vai trò chính
API Service	Tệp và metadata	Material + job	Kiểm tra scope, loại tệp, checksum và enqueue parse-index.
Parse-index pipeline	Material thô	Parsed pages	Điều phối Docling, OCR/VLM, Whisper, Spreadsheet parser.
Evidence mapper / Chunker	Parsed blocks	Evidence Unit + chunks	Giữ page, block_id, bbox, timestamp và source_language.

Thành phần	Đầu vào	Đầu ra	Vai trò chính
Storage	Metadata + vectors	MongoDB + Qdrant	Lưu chunks, KG, logs và dense/sparse/visual vectors theo scope.
Retrieval layer	Query đã xử lý	Candidate evidence	Truy xuất dense-sparse, graph paths và visual evidence.
Rerank / context	Candidate evidence	Evidence Bundle	Sắp xếp lại, loại trùng và đóng gói context có citation.
Guardrails	Draft evidence	Answer/refusal	Kiểm tra EvidenceValidator, SLEC, Citation Alignment và Quality Gate.
Table executor	Câu hỏi số liệu	Kết quả + ô dữ liệu	Xử lý lookup/aggregation bằng mã nguồn tắt định.
Observability	Runtime trace	Query log	Ghi stage, latency, citations, quality verdicts và lỗi fallback.

2.8. Bộ xử lý bảng biểu tắt định

LLM thường không ổn định khi thực hiện phép toán trên bảng, đặc biệt với các yêu cầu cộng, lọc, so sánh hoặc tổng hợp nhiều ô dữ liệu. Vì vậy, xử lý bảng được tách khỏi quá trình sinh ngôn ngữ. Khi câu hỏi số liệu được phát hiện, full table/grid được nạp từ MongoDB và phép toán được thực thi bằng mã nguồn tắt định.


Kết quả trả về gồm đáp án và vị trí các ô dữ liệu được sử dụng. Nhờ đó, quá trình tính toán có thể được kiểm tra lại thay vì chỉ nhận một con số do mô hình sinh ra từ vài dòng được truy xuất.

2.9. Kiểm chứng sau sinh

Kiểm chứng sau sinh là bước kiểm tra trước khi câu trả lời được trả về. Câu trả lời nháp được tách thành các câu khẳng định, sau đó từng câu được đối chiếu với các

Evidence Unit đã truy xuất. Nếu một khẳng định không có đủ bằng chứng, nội dung đó có thể bị loại bỏ hoặc câu trả lời được chuyển sang trạng thái từ chối.

Bên cạnh SLEC, Citation Alignment được dùng để kiểm tra sự khớp giữa nội dung câu trả lời và thẻ trích dẫn. Quality Gate tổng hợp confidence, evidence coverage và citation coverage. RequestTrace, QueryLog và PipelineJob được dùng để ghi lại stage, latency, citations, quality verdicts và lỗi khi pipeline cần fallback hoặc từ chối.



Hình 2.8. Kiểm chứng trích dẫn sau sinh và công kiểm soát chất lượng


Ở Hình 2.8, kiểm chứng sau sinh được thực hiện ở mức câu. Mỗi câu trong câu trả lời nháp được chấm mức hỗ trợ bằng chứng; các câu chưa đủ căn cứ được xử lý, citation marker được đánh số lại và sự căn chỉnh giữa citation marker với đoạn bằng chứng được kiểm tra. Quality Gate đặt điều kiện để câu trả lời chỉ được chấp nhận khi mức hỗ trợ bằng chứng đạt ngưỡng đã định.

CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

3.1. Thiết lập thực nghiệm

Thực nghiệm được triển khai trong môi trường cục bộ nhằm kiểm soát dữ liệu và đánh giá khả năng vận hành của hệ thống trên hạ tầng cá nhân. Qwen2.5-7B-Instruct được dùng cho xử lý ngôn ngữ và sinh câu trả lời [5]; Qwen2.5-VL-3B-Instruct được dùng cho nội dung thị giác [6]; BGE-M3 được dùng cho embedding dense và sparse [7].

Các tham số thực nghiệm như temperature, max tokens, số lượng bằng chứng top-k, ngưỡng kiểm chứng và seed được giữ cố định giữa các cấu hình. Nhờ cách thiết lập này, việc so sánh tập trung vào tác động của từng thành phần kỹ thuật thay vì phụ thuộc vào cấu hình sinh khác nhau.



Hình 3.1. Quy trình đánh giá thực nghiệm và ablation

Ở Hình 3.1, logic đánh giá được trình bày theo chuỗi từ tập tài liệu, nhãn chuẩn, cấu hình thử nghiệm đến ablation. Cùng một tập tài liệu và nhãn chuẩn được dùng cho nhiều cấu hình, nhờ đó ảnh hưởng của từng thành phần có thể được xem xét riêng biệt. Cách đánh giá này phân biệt thành phần phục vụ truy xuất, thành phần phục vụ kiểm chứng và thành phần làm tăng chi phí xử lý.

3.2. Bộ dữ liệu đánh giá


Bộ dữ liệu đánh giá được xây dựng bằng cách kết hợp sinh câu hỏi có kiểm soát và rà soát thủ công. Tổng cộng có 294 câu hỏi trên 12 tài liệu với 362 trang hoặc slide.

Các câu hỏi bao phủ các nhóm tình huống: hỏi đáp trực tiếp, câu hỏi bắc cầu, bảng biểu, nội dung thị giác, truy vấn đa ngữ và câu hỏi không có đủ thông tin trong tài liệu.

Bảng 3.1. Cơ cấu bộ dữ liệu đánh giá

Nhóm câu hỏi	Số lượng	Tỷ lệ	Mục đích đánh giá
Factual QA	114	38,8%	Đánh giá câu hỏi có đáp án trực tiếp trong tài liệu.
Multi-hop/Graph & Comparison	50	17,0%	Đánh giá câu hỏi cần kết hợp nhiều phần thông tin.
Table/Numerical QA	20	6,8%	Đánh giá câu hỏi cần tính toán trên bảng.
Visual QA	12	4,1%	Đánh giá câu hỏi dựa trên ảnh quét hoặc biểu đồ.
Audio/Cross-lingual	35	11,9%	Đánh giá nội dung âm thanh và truy vấn đa ngữ.
Unanswerable/Refusal QA	63	21,4%	Đánh giá phản hồi trong trường hợp tài liệu không đủ thông tin.

Bộ dữ liệu được chia theo tài liệu thay vì chia ngẫu nhiên theo câu hỏi. Cách chia này làm giảm nguy cơ rò rỉ thông tin giữa các tập dữ liệu và phản ánh sát hơn tình huống hệ thống phải xử lý tài liệu mới.



Hình 3.2. Quy trình tạo bộ dữ liệu đánh giá cho RAG

Ở Hình 3.2, quy trình tạo bộ dữ liệu đánh giá gồm sinh ứng viên, lọc tự động, rà soát độc lập và hòa giải. Việc kết hợp các bước này nhằm giảm số câu hỏi mơ hồ, trùng lặp hoặc không thể trả lời. Tập kiểm thử cuối cùng có đáp án chuẩn, bằng chứng chuẩn và tọa độ dẫn chứng, phù hợp để đánh giá cả chất lượng trả lời lẫn chất lượng trích dẫn.

3.3. Chỉ số đo lường

Năm chỉ số được sử dụng để đánh giá chất lượng truy xuất, chất lượng câu trả lời, chất lượng trích dẫn và khả năng từ chối khi thiếu bằng chứng:

- Recall@k: tỷ lệ câu hỏi mà hệ thống truy xuất được bằng chứng chuẩn trong top-k kết quả.
- Answer F1: mức độ khớp giữa câu trả lời sinh ra và đáp án chuẩn.
- Citation F1: mức độ chính xác của các nguồn được trích dẫn so với bằng chứng thực sự hỗ trợ câu trả lời.
- Supported-claim rate: tỷ lệ câu khẳng định trong câu trả lời được chứng thực bởi tài liệu nguồn.
- Refusal F1: khả năng nhận biết và từ chối các câu hỏi không có đủ thông tin trong tài liệu.

3.4. Kết quả thực nghiệm

So sánh với các baseline

Bảng 3.2 trình bày kết quả so sánh giữa hệ thống đề xuất và các baseline. Các cấu hình được sắp xếp theo mức độ bổ sung thành phần kỹ thuật để quan sát ảnh hưởng của truy xuất lai, đồ thị tri thức và kiểm chứng sau sinh. Cách đánh giá này tương ứng với các tiêu chí thường dùng trong benchmark RAG như truy xuất, tích hợp thông tin và từ chối khi thiếu bằng chứng [4].

Bảng 3.2. So sánh hiệu năng tổng thể giữa các cấu hình

Cấu hình	R@5	Ans	Cit	Sup	Ref	p95
Plain Vector RAG	0,22	0,11	0,34	0,47	0,00	113
Hybrid RAG	0,61	0,58	0,59	0,71	0,00	260
Hybrid + Graph	0,75	0,70	0,69	0,80	0,33	363
Full AgentBook	0,79	0,67	0,59	0,76	0,36	346

Cấu hình đầy đủ ghi nhận Recall@5 là 0,79, cao hơn các cấu hình còn lại trong cùng thiết lập. Sự chênh lệch so với Plain Vector RAG gợi ý rằng biểu diễn tài liệu bằng Evidence Unit kết hợp truy xuất lai có liên hệ với khả năng tìm đúng bằng chứng. Answer F1 của cấu hình đầy đủ thấp hơn nhẹ so với Hybrid + Graph; nguyên nhân có thể liên quan đến bước kiểm chứng sau sinh, khi các khẳng định chưa đủ bằng chứng bị giảm mức khẳng định hoặc bị loại bỏ.

Supported Rate của cấu hình Full là 0,76, cao hơn Plain Vector RAG. Kết quả này phản ánh việc kiểm soát mối liên hệ giữa câu trả lời và tài liệu nguồn, thay vì chỉ dựa trên số lượng đoạn liên quan được truy xuất. Độ trễ còn cao do mô hình được chạy cục bộ và có thêm bước kiểm chứng; đây là hạn chế cần được xem xét nếu hệ thống được triển khai trong môi trường yêu cầu phản hồi nhanh.

Thử nghiệm thành phần

Bảng 3.3 phân tích tác động của từng thành phần theo hướng cộng dồn. Cách trình bày này được dùng để xác định thành phần liên quan đến chất lượng truy xuất và thành phần làm phát sinh thêm chi phí xử lý.

Bảng 3.3. Đóng góp của từng thành phần kỹ thuật trong Ladder Ablation

Cấu hình	R@5	Sup	Cit	Ref	p50
C0 - Dense-only	0,22	0,47	0,34	0,00	34
C1 - Hybrid Sparse	0,61	0,71	0,59	0,00	93
C2 - Rerank	0,78	0,75	0,65	0,00	201
C3 - Correctness	0,74	0,84	0,73	0,33	201
C4 - SLEC	0,78	0,77	0,69	0,36	220
Full	0,79	0,76	0,59	0,36	275

Trong ladder ablation, hai thành phần có liên hệ đáng chú ý với Recall@5 là Hybrid Sparse và Cross-Encoder Rerank. Sau khi tín hiệu sparse được bổ sung, Recall@5 chuyển từ 0,22 sang 0,61 nhờ sự kết hợp giữa tín hiệu ngữ nghĩa và tín hiệu từ khóa. Ở cấu hình có reranker, Recall@5 đạt 0,78 do các bằng chứng ứng viên được sắp xếp lại theo mức độ liên quan với câu hỏi. Kết quả này phù hợp với vai trò của truy xuất đa chức năng trong các hệ thống RAG hiện đại [7].

Các thành phần kiểm chứng không tạo ra xu hướng tăng đồng nhất ở mọi chỉ số, nhưng hành vi trả lời có xu hướng thận trọng hơn. Với Correctness Verification và SLEC, Refusal F1 chuyển từ 0 sang 0,36, nghĩa là một phần câu hỏi thiếu bằng chứng đã được nhận diện. Đây là tiêu chí cần quan tâm đối với các hệ thống RAG có yêu cầu kiểm soát hallucination và negative rejection [2], [4].

KẾT LUẬN

Trong đồ án, AgentBook được thiết kế và triển khai thử nghiệm cho bài toán hỏi đáp trên tài liệu đa phương thức theo hướng bảo toàn và kiểm chứng dẫn chứng. Trọng tâm của hệ thống là Evidence Unit, được sử dụng xuyên suốt từ nạp liệu, tạo chỉ mục, truy xuất, sinh câu trả lời đến kiểm chứng sau sinh. Cấu trúc này cho phép nội dung trả lời liên kết ngược về tài liệu gốc thay vì chỉ dừng ở mức trích dẫn chung.

Kết quả thực nghiệm trên bộ dữ liệu 294 câu hỏi ghi nhận Recall@5 là 0,79, Supported-claim rate là 0,76 và Refusal F1 là 0,36. Các giá trị này phản ánh đóng góp của truy xuất lai, đồ thị tri thức nhẹ, reranking và kiểm chứng sau sinh ở các khía cạnh khác nhau của hệ thống. Cơ chế từ chối khi thiếu bằng chứng có ý nghĩa trong những tình huống yêu cầu độ tin cậy cao.

Một số hạn chế vẫn còn tồn tại, gồm thời gian phản hồi do mô hình chạy cục bộ và chi phí của các bước kiểm chứng. Chất lượng trích xuất cũng phụ thuộc vào chất lượng tài liệu đầu vào, đặc biệt với ảnh quét mờ, bảng phức tạp hoặc bố cục không chuẩn. Hướng phát triển tiếp theo gồm tối ưu mô hình, cache kết quả truy xuất, hoàn thiện giao diện hiển thị bbox và mở rộng đánh giá trên các tập tài liệu chuyên ngành lớn hơn.

TÀI LIỆU THAM KHẢO

- [1] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459-9474, 2020.
- [2] Y. Gao et al., “Retrieval-Augmented Generation for Large Language Models: A Survey,” *arXiv preprint arXiv:2312.10997*, 2023.
- [3] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 157-173, 2024.
- [4] J. Chen, H. Lin, X. Han, and L. Sun, “Benchmarking Large Language Models in Retrieval-Augmented Generation,” *arXiv preprint arXiv:2309.01431*, 2023.
- [5] A. Yang et al., “Qwen2.5 Technical Report,” *arXiv preprint arXiv:2412.15115*, 2024.
- [6] S. Bai et al., “Qwen2.5-VL Technical Report,” *arXiv preprint arXiv:2502.13923*, 2025.
- [7] J. Chen et al., “BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” *Findings of the Association for Computational Linguistics: ACL 2024*, pp. 11148-11159, 2024.
- [8] C. Cui et al., “PaddleOCR 3.0 Technical Report,” *arXiv preprint arXiv:2507.05595*, 2025.